Tarea 1.2 Regresion Lineal Simple

1. En el siguiente bloque de codigo se importara la base de datos felicidad&GDP.csv con la funcion read_csv() de la libreria pandas. Tambien se imprimiran los paises mas felices y los que tienen mayor GDP

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import scipy.stats as stats
import statsmodels.api as sm
df = pd.read_csv('felicidad&GDP.csv')

tabla_felicidad = df.sort_values('Felicidad',ascending=False)
print('Top 10 paises mas felices de acuerdo a nuestra base de datos: ')
print(tabla_felicidad.head(10), '\n')
tabla_GDP = df.sort_values(by = 'GDP',ascending=False)
print('Top 10 paises con mayor GDP de acuerdo a nuestra base de datos: ')
print(tabla_GDP.head(10))
```

```
Top 10 paises mas felices de acuerdo a nuestra base de datos:
           Pais  Felicidad           GDP
0       Finland     7.8210  2.718370e+11
1       Denmark     7.6362  3.560850e+11
2       Iceland     7.5575  2.171808e+10
3   Switzerland     7.5116  7.522480e+11
4   Netherlands     7.4149  9.138650e+11
5    Luxembourg     7.4040  7.335313e+10
6        Sweden     7.3843  5.414870e+11
7        Norway     7.3651  3.621980e+11
8        Israel     7.3638  4.071010e+11
9   New Zealand     7.1998  2.117350e+11

Top 10 paises con mayor GDP de acuerdo a nuestra base de datos:
              Pais  Felicidad           GDP
15    United States     6.9768  2.089370e+13
70            China     5.5853  1.468770e+13
52            Japan     6.0389  5.040110e+12
13          Germany     7.0341  3.846410e+12
16   United Kingdom     6.9425  2.756900e+12
130           India     3.7771  2.667690e+12
19           France     6.6867  2.630320e+12
29            Italy     6.4667  1.892570e+12
14           Canada     7.0251  1.645420e+12
57       South Korea     5.9351  1.637900e+12
```

2. En el siguiente bloque de codigo, se graficara el nivel de felicidad de acuerdo al nivel, en logaritmo base 10, del GDP, utilizando el comando log10() de la libreria numpy.

```
x = np.log10(df['GDP'])
y = df['Felicidad']

plt.figure(figsize=(10,5))
plt.title('Grafica 1. Felicidad vs GDP',fontsize = 12)
plt.grid(True, alpha = 0.25,linestyle = '--')
plt.scatter(x,y)
plt.xlabel('GDP')
plt.ylabel('Felicidad')
plt.show()
```

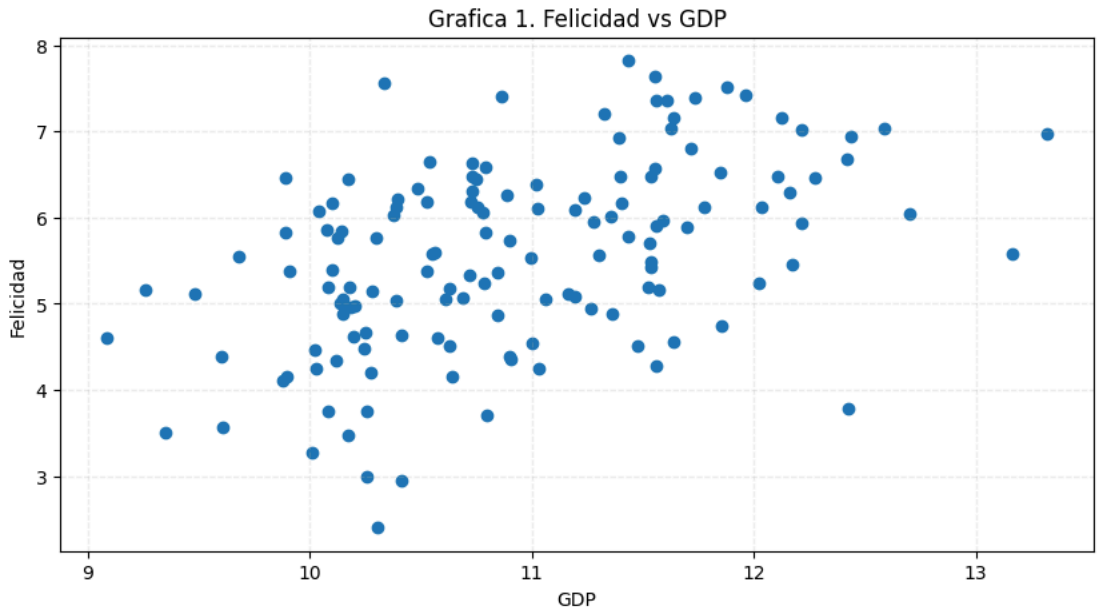

3. A continuacion, se calcularan los dos coeficientes de nuestro modelo de regresion lineal simple, utilizando las formulas vistas en clase, y las funciones de numpy, sum y mean.

```
mean_x = np.mean(x)
mean_y = np.mean(y)
beta_1 = np.sum((x - mean_x)*(y - mean_y))/np.sum((x - mean_x)**2)
beta_0 = mean_y - beta_1*mean_x

print('Coeficiente beta 1: ',beta_1)
print('Coeficiente beta 0: ',beta_0)
```

```
Coeficiente beta 1:  0.628128465881041
Coeficiente beta 0:  -1.3023500570747295
```

4. En el siguiente bloque, se graficaran de nuevo, junto con el nuevo modelo de regresion lineal simple.

```
modelo = beta_0 + beta_1*x

plt.figure(figsize=(10,5))
plt.title('Grafica 2. Felicidad vs GDP',fontsize = 12)
plt.grid(True, alpha = 0.25,linestyle = '--')
plt.scatter(x,y, alpha = 0.75)
plt.xlabel('GDP')
plt.ylabel('Felicidad')

x_linea = [min(x),max(x)]
y_linea = [beta_0 + beta_1*x_linea[0],beta_0 + beta_1*x_linea[1]]
plt.plot(x_linea,y_linea,'r', alpha = 0.75)

plt.show()
```

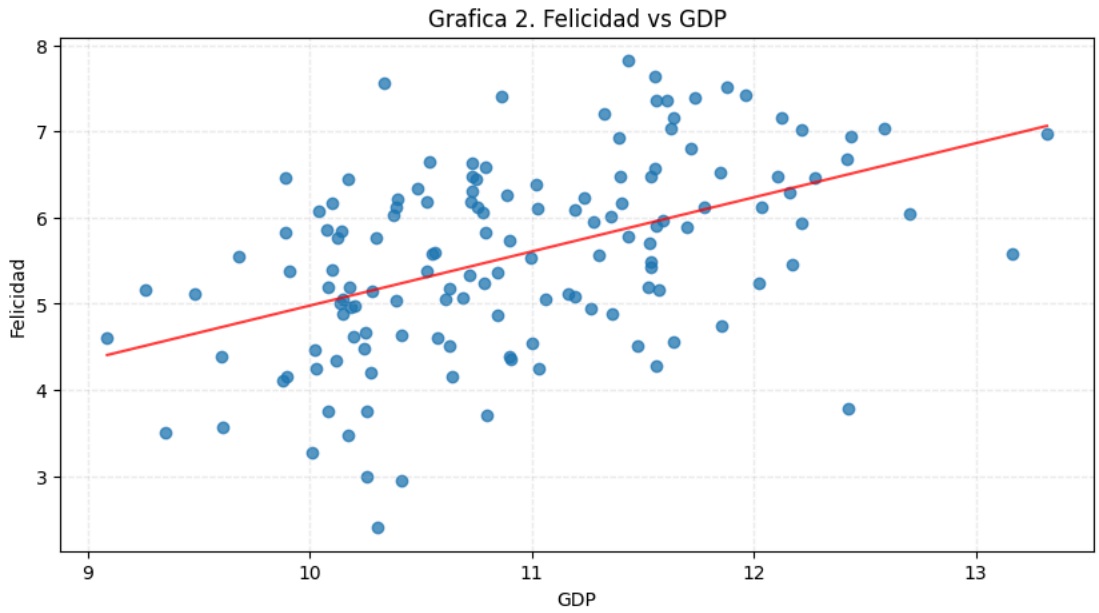

Observando la grafica anterior, podemos darnos cuenta que la linea de tendencia esta pasando por el centro del area observada en los puntos de nuestra base de datos.

5. A continuacion se calculara el RSS (Residual Sum of Squares) de nuestro modelo, para poderlo utilizar despues en los caluclos de nuestro error estandar de los coeficientes y en el RSE (Residual Standard Error), que sera el error promedio tipico de nuestro modelo

```
e = np.zeros(len(y))
for i in range(len(y)):
  e[i] = y[i] - modelo[i]

RSS = np.sum(e**2)
print('RSS: ',RSS)
```

```
RSS:  131.3738317732635
```

6. En el siguiente bloque, calcularemos el error estandar de los coeficientes y el intervalo de confianza del 95% de beta 1.

```
SE_beta1 = np.sqrt(RSS/(len(y) - 2))*1/np.sqrt(np.sum((x - mean_x)**2))
print('Error estandar de beta 1: ',SE_beta1)

t = beta_1/SE_beta1
print('Estadistico t: ',t)
gdl = len(y) - 2
print('Grados de libertad: ',gdl)
p_value = 2*(1 - stats.t.cdf(t,gdl))
print('Valor p: ',p_value)

print('Intervalos de confianza: ', [beta_1 - p_value*SE_beta1,
                                    beta_1 + p_value*SE_beta1])

print('\nDebido a que el valor p es menor que nuestro nivel de significancia ')
print('de 5%, podemos decir que sí existe una relacion significativa entre el ')
print('nivel de felicidad y el valor de GDP en logaritmo base 10 ')
```

```
Error estandar de beta 1:  0.09983378435340727
Estadistico t:  6.291742519320849
Grados de libertad:  139
Valor p:  3.825717964645037e-09
Intervalos de confianza:  [0.6281284654991051, 0.6281284662629769]

Debido a que el valor p es menor que nuestro nivel de significancia
de 5%, podemos decir que sí existe una relacion significativa entre el
nivel de felicidad y el valor de GDP en logaritmo base 10
```

7. A continuacion, se calculara el RSE y la R^2, para saber el error promedio de nuestro modelo y que tan adecuado es para el sistema para los datos utilizados.

```
# Otra forma de calcular ESS y TSS
#z = np.zeros(len(y))
#g = np.zeros(len(y))
#for i in range(len(y)):
#  z[i] = (y[i] - mean_y)**2
#for i in range(len(y)):
 # g[i] = (modelo[i] - mean_y)**2
#ESS = np.sum(g)


RSE = np.sqrt(RSS/(gdl))

ESS = np.sum((modelo - mean_y)**2)
TSS = np.sum((y - mean_y)**2)

R2 = ESS/TSS

print('RSE: ',RSE)
print('TSS: ',TSS)
print('ESS: ',ESS)
print('R^2: ',R2)

print('\nObservando R^2, podemos concluir que este modelo de regresion lineal')
print('simple, no es el adecuado, ya que el valor de R^2 es muy bajo. ')
print('Lo cual me hace sentido, al observar la grafica 2, se puede ver que')
print('los datos estan muy dispersos en comparacion con la linea de tendencia. ')
```

```
RSE:  0.9721807858537376
TSS:  168.78798751626567
ESS:  37.41415574300217
R^2:  0.22166361654970654

Observando R^2, podemos concluir que este modelo de regresion lineal
simple, no es el adecuado, ya que el valor de R^2 es muy bajo.
Lo cual me hace sentido, al observar la grafica 2, se puede ver que
los datos estan muy dispersos en comparacion con la linea de tendencia.
```

8. Para concluir, se utilizara la funcion OLS() de la libreria statsmodels.api, para verificar que los resultados anteriores son correctos.

```
modelo_2 = sm.OLS(y,sm.add_constant(x))
modelo_2 = modelo_2.fit()
print(modelo_2.summary())
pvalues = modelo_2.pvalues

print('\nValor de p: ', f"{pvalues[0]:.15f}",'\n            ', f"{pvalues[1]:.15f}")
print('RSE:', modelo_2.scale**.5,'\n')
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:              Felicidad   R-squared:                       0.222
Model:                            OLS   Adj. R-squared:                  0.216
Method:                 Least Squares   F-statistic:                     39.59
Date:                Mon, 27 Jan 2025   Prob (F-statistic):           3.83e-09
Time:                        02:27:37   Log-Likelihood:                -195.09
No. Observations:                 141   AIC:                             394.2
Df Residuals:                     139   BIC:                             400.1
Df Model:                           1
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const         -1.3024      1.094     -1.191      0.236      -3.465       0.860
GDP            0.6281      0.100      6.292      0.000       0.431       0.826
==============================================================================
Omnibus:                        2.648   Durbin-Watson:                   0.455
Prob(Omnibus):                  0.266   Jarque-Bera (JB):                2.523
Skew:                          -0.326   Prob(JB):                        0.283
Kurtosis:                       2.944   Cond. No.                         148.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

Valor de p:  0.235797533420326
```

```
                0.000000003825718
RSE: 0.9721807858537376

<ipython-input-19-6b279390fdc8>:6: FutureWarning: Series.__getitem__ treating keys as positions is deprecated. In a future version, inte
```